Tarea Sesión 2.1

Bioinformática y análisis genómicos reproducibles

Joaquín Torres Nuñez

Profesor: Ricardo Verdugo

30/09/2026

1. Realizar las siguientes tareas tanto para las secuencias crudas y podadas. Además de generar los informes de calidades deben realizar una comparación de los resultados. Recuerden que la ubicación de las secuencias crudas es en el directorio: 181004_curso_calidad_datos_NGS/fastq_raw/ y las secuencias ya podadas se encuentran en 181004_curso_calidad_datos_NGS/fastq_filter

Usando comandos Unix:

1. Contar el número de lecturas (reads) en un archivo fastq Se tomara como ejemplo el archivo fastq_raw S14_R1.fastq y S14_R1_filter.fastq

```
zgrep -c "^+$" S14_R1.fastq.gz
```

Respuesta: **10209 reads**

```
zgrep -c "^+$" S14_R1_filter.fastq.gz
```

Respuesta: **8038 reads**

Se evidencia una clara disminución en el numero de reads post filtrado.

2. Previsualizar las primeras 40 líneas del mismo archivo fastq

```
zcat ../181004_curso_calidad_datos_NGS/fastq_raw/S3_R1.fastq.gz | head -n
40
zcat ../181004_curso_calidad_datos_NGS/fastq_filter/S3_R1_filter.fastq.gz |
head -n 40
```

3. Ubicar la lectura 3 e identificar la información disponible. Describir en detalle la información entregada. ¿Donde se entrega la calidad del read?, ¿Cuál es el ID (identificador) del read? Etc. Utilice

fechas y etiquetas para identificar cada parte.

```
zcat ../181004_curso_calidad_datos_NGS/fastq_raw/S3_R1.fastq.gz | head -n
12 | tail -n 4
```

- Se entregan 4 líneas de informarción en la consola:
  - La primera corresponde a los datos de identificación de la lectura.
  - La segunda linea entrega la secuencia nuebelotidica del fragemnto.
  - Posteriormente viene una tercera alínea "+" la cual cumple la función de separador.
  - Finalmente la cuarta línea corresponde a la información de la calidad de la secuencia, donde cada letra/simbolo representa un score de calidad (Phred score)

La calidad del read se entrega en la cuarta linea, representada en simbolos particulares por cada base que compone la secuencia.

Id de la muetra: @M03564:2:000000000-D29D3:1:1101:16551:1405 1:N:0:ATCACGAC+TAAGACAC

4. Traducir el código de calidad para las primeras 10 bases del tercer read a valores numéricos (Q) usando la codificación entregada en clase. Secuencia nucleotídica: AAGCTGACAG Calidad de la secuencia: CCBCCFFFFF

En base a la tabla ASCI base-33 la traducción del código a Phred score por base sería: 34/34/33/34/34/37/37/37/37/37

5.Determinar el número de regiones blanco en el panel, analizando el archivo ls 181004_curso_calidad_datos_NGS/regiones_blanco.bed El archivo regiones_blanco.bed que estás analizando es el archivo de coordenadas genómicas que define la lista exacta de esas regiones blanco en el genoma de referencia.

```
wc -l ../181004_curso_calidad_datos_NGS/regiones_blanco.bed
```

Respuesta: **Archivo contiene 369 regiones blanco.**

2. Genere un informe de calidad con FastQC para una muestra (cada estudiante una muestra distinta), para R1 y R2.

Se realizará un informe de calidad para la secuencia S14_R1.fastqc.gz/S14_R2.fastqc.gz de secuencias crudas y podadas

1

- 1. Reporte de lecturas crudas (Raw) fastqc ../181004_curso_calidad_datos_NGS/fastq_raw/SX_R1.fastq.gz ../181004_curso_calidad_datos_NGS/fastq_raw/SX_R2.fastq.gz -o .
- 2. Reporte de lecturas filtradas (Filter) fastqc ../181004_curso_calidad_datos_NGS/fastq_filter/S14_R1_filter.fastq.gz ../181004_curso_calidad_datos_NGS/fastq_filter/S14_R2_filter.fastq.gz -o .

3. Baje los archivos HTML a su computados mediante sftp (puede usar cualquier cliente o la línea de comandos. Por ejemplo, ejecutando desde su computador local: scp bioinfo1@genoma.med.uchile.cl:ricardo/S3_R1_fastqc* .

```
scp bioinfo1@genoma.med.uchile.cl:~/jtorresnunez/*.html .
```

4. Analice el informe de calidad creado con fastqc para las lecturas R1 y R2.

- S14_R1_fastqc: Se analizó un total de 10209 lecutras, con un total de 2.5 MB. Con un largo de secuencias de 251 pb. Al analizar el gráfico "per base sequence quality se observa que desde las bases 165-169 decae la calidad de la secuencia, donde en la posición >239 decae bajo 30 Phred score. Tanto "Per tile sequence quality", como "Per sequence quality scores" aprobaron en calidad. Se observa una advertencia en "Per base sequence content" reflejado en un desvío en la proporcion de bases nucleotidicas A,T,C,G. "Per sequence GC content" falló, no obstante este elemento debe ser tomado en consideración dado que se basa en genoma humano, en casos de genomas no convencionales dicha proporcion podria no siempre ser lo normal. "Per base N content", "Sequence Length Distribution" fueron aprobados en su calidad. "Sequence Duplication Levels" falló indicando alto % de lecturas duplicadas, detectando ademas la presencia de adaptadores, lo que tiene sentido puesto que aun no se aplica filtro ni trimming a las secuencias.

- S14_R2_fastqc: Se observó de igual forma un total de 10209 lecturas, con un total de 2.5 MB, no obstante, como era de esperar, estas poseen una menor calidad, disminuyendo el Phred score de forma drástica a partir de la base 135-139, observandose un score de calidad <30 desde las bases 185-189. ESta disminución de la calidad se refleja en señales de "Warning" en "per base sequence quality" y señakes de "fail" en "per base sequence content"

- S14_R1_filterfastqc: Al comparar con S14_raw, al aplicar filtro se evidencian cambios importantes en el informe de calidad. Disminuyen de forma significativa el número de lecturas anlizadas (8038 secuencias), con un total de 1.8 Mbp. A su vez se aplico filtro de largo del fragmento. Per base sequence quality pasó el filtro así como "Adapter content" demostrando que los adaptadores de secuenciación fueron removidos exitosamente por debajo del umbral de detección (PASS).

- S14_R2_filterfastqc: La longitud de lectura pasó de ser fija a un rango de 35 a 251 pares de bases. Esto generó una advertencia (WARNING) en el módulo Sequence Length Distribution, lo cual es el comportamiento esperado tras aplicar algoritmos de recorte por calidad o remoción de adaptadores. Adapter Content, al igual que S14_R1_filter aprobó lo que indica una correcta remoción de adaptadores. Respecto a "Per base sequence quality" se observá una mejora en la caldiad de las lecturas, aprobando este indicador. Tras el filtrado, el archivo conserva un total de 8,038 secuencias (~1.6 Mbp) con 0 secuencias marcadas como deficientes (poor quality).

5. Compare los valores calculados en el punto 1 con lo entregado en el informe de calidad obtenido con FastQC

- Número de lecturas:
S14_R1_fastqc comandos UNIX: 10209 reads S14_R1_fastqc FASTQC: 10209 reads S14_R2_fastqc comandos UNIX:10209 reads S14_R2_fastqc FastQc: 10029 reads S14_R1_filter_fastqc comandos UNIX: 8038 S14_R1_filter_fastqc FastQc: 8038 S14_R2_filter_fastqc comandos UNIX: 8038

S14_R2_filter_fastqc FastQc: 8038 No se evidencia cambios en el número de reads entre comandos Unix y programa FastQc.

- Calidad de las secuencias **Secuencia S14_fastqc primeras 10 bases:**
- S14_R1: ACTAAGGAAC
- S14_R2: ATCTATATTC
- Qscores S14_R1_fastqc: EEEEEFFFFF
- Qscores S14_R2_fastqc: ABCCCFFFFF

Qscores en informe de calidad FastQC

- S14_R1_fastqc: 34/34/34/35/35/36/36/36/37
- S14_R2_fastqc: 33/33/34//34/34/36/36/36/37

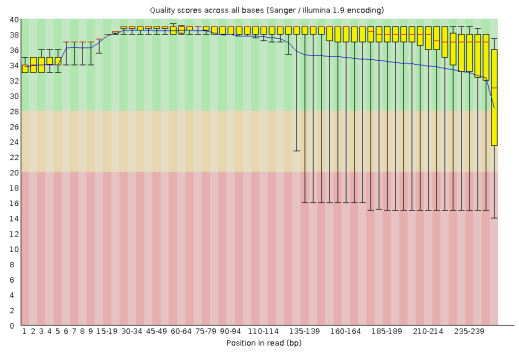
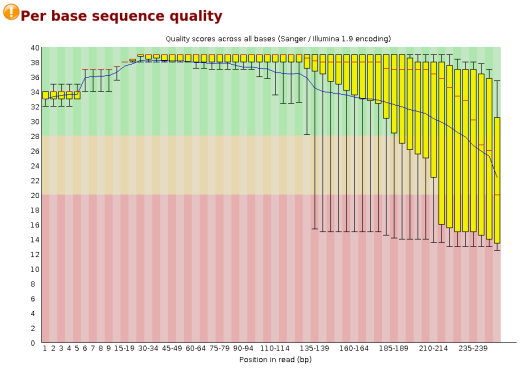
Qscores de secuencias filtradas en informe de calidad FastQC

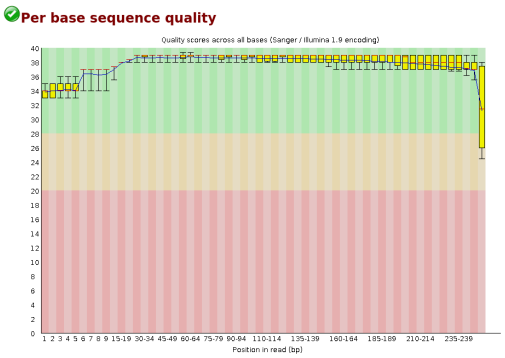
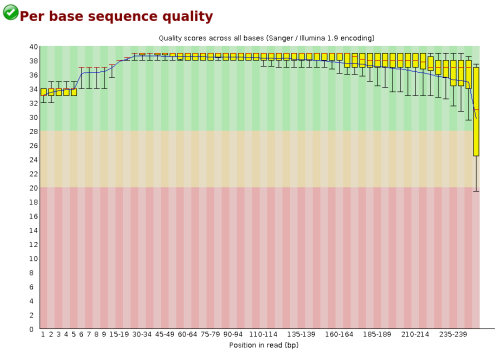
- S14_R1_filter_fastqc: 34/34/34/35/35/36/36/36/36/37
- S14_R2_filter_fastqc: 34/34/34/34/34/36/36/36/36/37

Respuesta: **No hubo una variación del número de reads ni de los Phred scores entre el analisis de Qscores realizado por comandos Unix, y el análsis efectuado por FastQc.**

6. Seleccione las 4 figuras más importantes a su criterio para analizar la calidad de la corrida, cópielas a un archivo Markdown en su repositorio y agregue su interpretación de cada figura. Recuerde hacer la comparación de R1 y R2 para las secuencias crudas y las secuencias podadas.

a. Per base sequence quality: Esta figura muestra la distribución del puntaje Phred (**Q**) para cada posición del ciclo de secuenciación a lo largo de las lecturas

Condición	Read 1 (R1)	Read 2 (R2)
Crudas (Raw)		

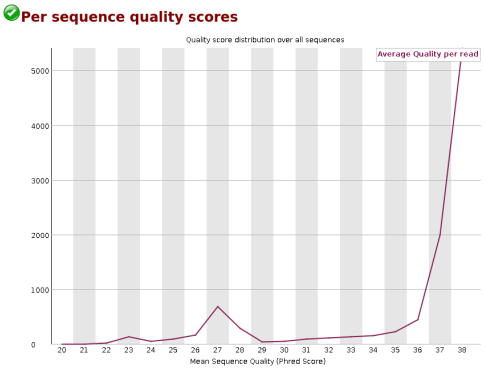
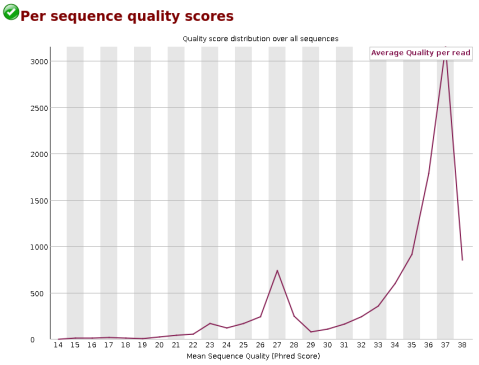
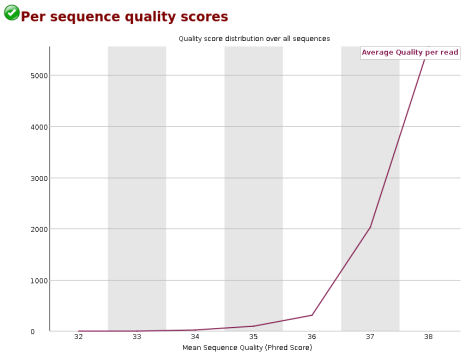
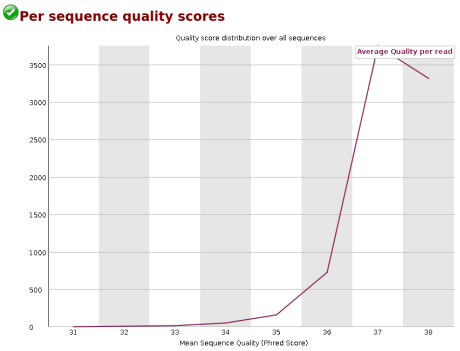
Condición	Read 1 (R1)	Read 2 (R2)
Podadas (Filter)		

Interpretación y Comparación:

- **Secuencias Crudas (Raw):**
  - **R1:** Mantiene puntajes de calidad Phred altos ($Q > 30$) a lo largo de casi todo el ciclo de lectura, con un leve descenso en los últimos nucleótidos.
  - **R2:** Muestra una caída en posiciones previas en comparacion a R1, ingresando en las zonas de menor Qscore ($Q20 - Q30$) y roja ($Q < 20$).
- **Secuencias Podadas (Filter):**
  - El proceso de podado (*trimming*) removió exitosamente las bases de mala calidad. En ambos archivos (**R1** y **R2**) practicamente el 100% de las posiciones se posiciona en la zona de alta calidad ($Q > 28$).

---

2. Per Sequence Quality Scores (Distribución de Calidad por Lectura)

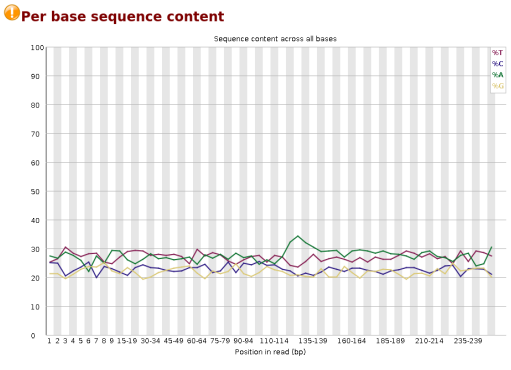
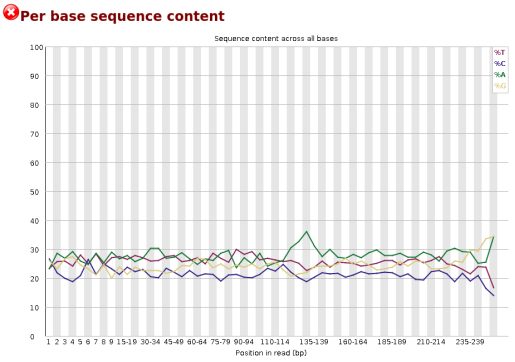
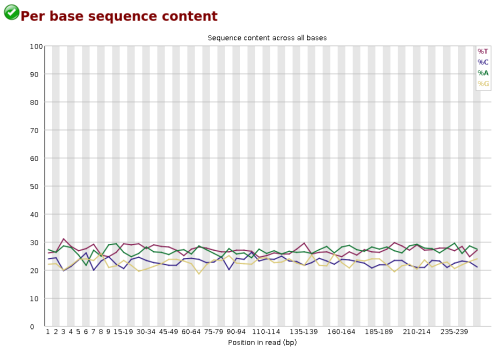
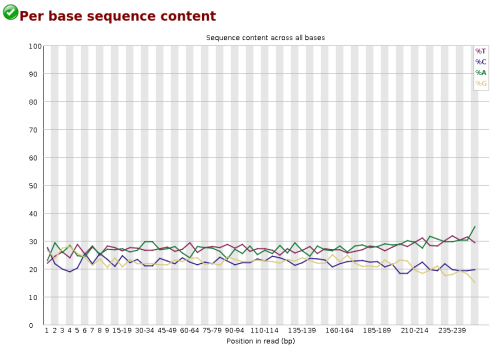
Condición	Read 1 (R1)	Read 2 (R2)
Crudas (Raw)		
Podadas (Filter)		

Interpretación y Comparación:

- **Secuencias Crudas (Raw):**
  - **R1, R2** presentan 2 peaks de distitna intensidad. El peak cercano al $Qscore = 27 - 28$ indica la presencia de bases de mala calidad, lo cual es esperable dado que aun no son sometidas al trimming.
- **Secuencias Podadas (Filter):**
  - Tras el filtrado, desaparece el peak observado con $Qscore = 27 - 28$ y curvas se vuelven homogeneas con una clara predominancia de las secuencias Q>30.

---

3. Per Base Sequence Content (Composición de Bases por Posición)

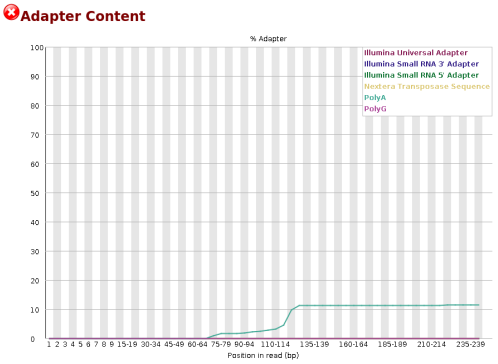
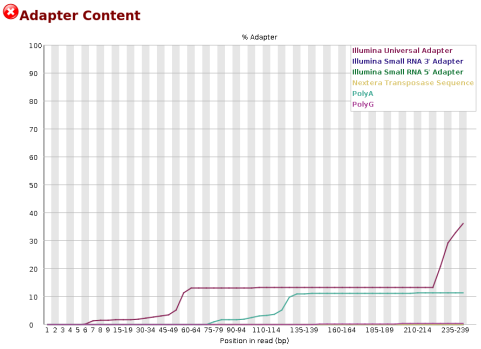
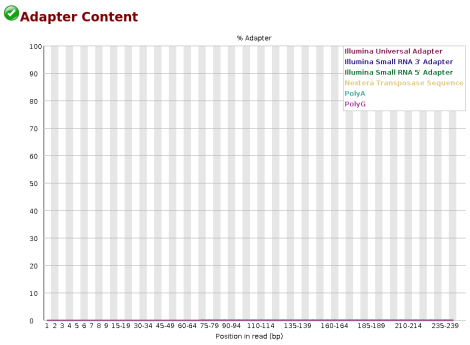
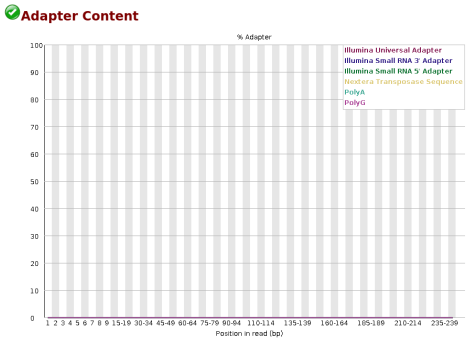
Condición	Read 1 (R1)	Read 2 (R2)
Crudas (Raw)		
Podadas (Filter)		

Interpretación y Comparación:

- **Secuencias Crudas (Raw):**
  - Tanto en Secuencias R1 como R2 se observa una mayor heterogeneidad en la distribucipon de bases nucleotidicas.
- **Secuencias Podadas (Filter):**
  - Al cortar las secuencias y retirar secuencais de mala calidad las proporciones de nucleótidos a lo largo del cuerpo de la lectura se estabilizan y corren paralelas.

---

4. Adapter Content (Contenido de Adaptadores)

Condición	Read 1 (R1)	Read 2 (R2)
Crudas (Raw)		
Podadas (Filter)		

Interpretación y Comparación:

- **Secuencias Crudas (Raw):**
  - Muestra una acumulación progresiva de secuencias de adaptadores hacia finald e las secuencias.
- **Secuencias Podadas (Filter):**
  - La tasa de presencia de adaptadores cae al **0%** plano a lo largo de toda la lectura tanto para **R1** como para **R2**, confirmando la efectividad del trimming

Conclusión

El control de calidad se consolida como una etapa previa fundamental e insustituible en cualquier flujo de trabajo genómico. La omisión o aplicación deficiente de este paso introduce artefactos técnicos, tales como lecturas con baja calidad Phred, capaces de alterar drásticamente los análisis de llos datos, derivando en resultados erroneos. Un anásis correcto de caldiad de las secuencias permitirá obtener resultados útiles para la comunidad cientifica, aspi como ensayos reproducibles, objetivos centrales de este curso. Por su parte, el software FastQC destaca como una herramienta de gran relevancia el análisis preliminar de datos NGS. Su capacidad para condensar millones de secuencias en métricas y visualizaciones gráficas facilita una revision dirigida de los datos, permitiendo identificar errores en la calidad de nuestras secuencias. Destaco de igual forma de esta tarea la experiencia de trabajar en servidores remotos, elemento que aporta en experiencia y herramientas en el trabajo de datos en bioinformática.